

**LAPORAN AKHIR**  
**PROYEK PENGANTI UAS**

Mata Kuliah Kecerdasan Buatan  
Semester Genap 2025/2026

**Perbandingan RNN, GRU, dan LSTM untuk Klasifikasi  
Sentimen Opini Publik Pilpres 2024**

Subjudul: RNN / GRU / LSTM

Disusun oleh:

|                           |                   |
|---------------------------|-------------------|
| Muhammad Hilmi Al Muttaqi | – NPM. 2306267082 |
| Reyhan Ahnaf Deannova     | – NPM. 2306267100 |
| Bryan Herdianto           | – NPM. 2306210885 |
| Adhikananda Wira Januar   | – NPM. 2306267113 |

Dosen Pengampu:

Muhammad Firdaus Syawaludin Lubis,  
S.T., M.T., Ph.D., CertDA

DEPARTEMEN TEKNIK KOMPUTER  
FAKULTAS TEKNIK  
UNIVERSITAS INDONESIA  
MEI 2026

## LEMBAR PERNYATAAN ORISINALITAS

Kami yang bertandatangan di bawah ini menyatakan bahwa laporan ini, beserta seluruh isinya (termasuk Sub-bab IV.x masing-masing anggota dan berkas *metadata.json* yang merupakan bagian tidak terpisahkan), adalah hasil karya kelompok kami sendiri. Setiap kutipan, kode, atau gambar yang berasal dari sumber lain telah disitasi dengan benar. Penggunaan *AI assistant* telah dideklarasikan secara jujur pada Sub-bab IV.x.2.

Muhammad Hilmi Al  
Muttaqi  
NPM. 2306267082



Reyhan Ahnaf  
Deannova  
NPM. 2306267100



Bryan Herdianto  
NPM. 2306210885



Adhikananda Wira Januar  
NPM. 2306267113



# DAFTAR ISI

|                                                                         |           |
|-------------------------------------------------------------------------|-----------|
| <b>LEMBAR PERNYATAAN ORISINALITAS.....</b>                              | <b>1</b>  |
| <b>DAFTAR ISI.....</b>                                                  | <b>2</b>  |
| <b>DAFTAR GAMBAR.....</b>                                               | <b>4</b>  |
| <b>DAFTAR TABEL.....</b>                                                | <b>4</b>  |
| <b>ABSTRAK.....</b>                                                     | <b>5</b>  |
| <b>BAB 1 PENDAHULUAN &amp; DEFINISI MASALAH.....</b>                    | <b>6</b>  |
| 1.1 Topik yang Dipilih.....                                             | 6         |
| 1.2 Rumusan Masalah.....                                                | 6         |
| 1.3 Tujuan Proyek.....                                                  | 7         |
| 1.4 Ruang Lingkup & Batasan.....                                        | 7         |
| <b>BAB 2 PENDEKATAN AI.....</b>                                         | <b>9</b>  |
| 2.1 Tinjauan Pustaka (Related Work).....                                | 9         |
| 2.2 Landasan Teori Model yang Dipilih.....                              | 10        |
| 2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI.....                     | 12        |
| 2.4 Block Diagram Sistem End-to-End.....                                | 13        |
| 2.5 Flowchart Program.....                                              | 14        |
| <b>BAB 3 IMPLEMENTASI &amp; HASIL EKSPERIMEN.....</b>                   | <b>16</b> |
| 3.1 Dataset & Pra-pemrosesan.....                                       | 16        |
| 3.2 Konfigurasi Eksperimen.....                                         | 17        |
| 3.3 Metrik Evaluasi.....                                                | 18        |
| 3.4 Hasil Kuantitatif.....                                              | 20        |
| 3.5 Analisis Hyperparameter Tuning.....                                 | 20        |
| 3.6 Hasil Kualitatif & Error Analysis.....                              | 20        |
| 3.7 Pembahasan.....                                                     | 22        |
| <b>BAB 4 PEMBAGIAN TUGAS &amp; DEKLARASI KONTRIBUSI INDIVIDUAL.....</b> | <b>23</b> |
| 4.1 Bryan Herdianto – NPM. 2306210885.....                              | 23        |
| IV.1.1 Komponen yang Dikerjakan.....                                    | 23        |
| IV.1.2 Pernyataan Penggunaan AI Assistant.....                          | 23        |
| 4.2 Reyhan Ahnaf Deannova – NPM. 2306267100.....                        | 23        |

|                                                                               |           |
|-------------------------------------------------------------------------------|-----------|
| IV.2.1 Komponen yang Dikerjakan.....                                          | 23        |
| IV.2.2 Pernyataan Penggunaan AI Assistant.....                                | 24        |
| 4.3 Muhammad Hilmi Al Muttaqi – NPM. 2306267082.....                          | 24        |
| IV.3.1 Komponen yang Dikerjakan.....                                          | 24        |
| IV.3.2 Pernyataan Penggunaan AI Assistant.....                                | 25        |
| 4.4 Adhikananda Wira Januar – NPM. 2306267113.....                            | 25        |
| IV.4.1 Komponen yang Dikerjakan.....                                          | 25        |
| IV.4.2 Pernyataan Penggunaan AI Assistant.....                                | 25        |
| <b>BAB 5 KESIMPULAN &amp; PEKERJAAN LANJUTAN.....</b>                         | <b>26</b> |
| 5.1 Kesimpulan.....                                                           | 26        |
| 5.2 Klaim Bonus Skor.....                                                     | 26        |
| 5.3 Pekerjaan Lanjutan (Future Work).....                                     | 26        |
| <b>DAFTAR PUSTAKA.....</b>                                                    | <b>27</b> |
| <b>LAMPIRAN A Berkas Metadata Proyek (JSON).....</b>                          | <b>28</b> |
| <b>LAMPIRAN B Tautan Repositori &amp; Dataset.....</b>                        | <b>32</b> |
| <b>LAMPIRAN C Research Participation Consent Form (Informed Consent).....</b> | <b>33</b> |
| Individual Consent — Member 1.....                                            | 34        |
| Individual Consent — Member 2.....                                            | 35        |
| Individual Consent — Member 3.....                                            | 36        |
| Individual Consent — Member 4.....                                            | 37        |

## DAFTAR GAMBAR

|                                                                                                                                               |    |
|-----------------------------------------------------------------------------------------------------------------------------------------------|----|
| Gambar 2.1: Arsitektur struktur sirkuit sel memori LSTM (a) dan GRU (b) beserta skema gating mechanism. (Sumber: Chung et al., 2014 [3])..... | 11 |
| Gambar 2.2: Block diagram sistem yang diusulkan.....                                                                                          | 14 |
| Gambar 2.3: Flowchart program training dan inference.....                                                                                     | 15 |
| Gambar 3.1 Confusion Matrix dari komparasi prediksi model Simple RNN, LSTM, dan GRU terhadap data pengujian.....                              | 21 |
| Gambar 3.2 Error Rate per Kelas Sentimen.....                                                                                                 | 22 |

## DAFTAR TABEL

|                                              |    |
|----------------------------------------------|----|
| Tabel 2.1: Ringkasan tinjauan pustaka.....   | 9  |
| Tabel 3.1: Status per tahapan pekerjaan..... | 16 |
| Tabel 3.2: Hyperparameter eksperimen.....    | 18 |
| Tabel 3.3: Hasil kuantitatif model.....      | 20 |

## ABSTRAK

Klasifikasi sentimen teks opini publik berbahasa Indonesia pada media sosial memiliki kompleksitas tinggi akibat tingginya dimensi *noise* semantik, seperti fragmentasi linguistik dan ambiguitas struktur kalimat. Penelitian ini mengevaluasi batas kapabilitas memori sekuensial jangka panjang dalam menangani anomali tekstual tersebut melalui analisis komparatif tiga arsitektur: *Simple RNN*, *Bidirectional Long Short-Term Memory (LSTM)*, dan *Bidirectional Gated Recurrent Unit (GRU)*. Eksperimen dikonstruksi menggunakan 29.728 sampel teks Twitter terkait Pemilihan Presiden Indonesia 2024, di mana ketidakseimbangan distribusi kelas sentimen diatasi melalui implementasi *class weight*. Representasi kinerja model diukur secara kuantitatif berdasarkan metrik *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan kompleksitas waktu komputasi (*training latency*). Hasil evaluasi empiris membuktikan bahwa mekanisme penapisan informasi (*gating mechanism*) bersifat esensial; arsitektur LSTM dan GRU berhasil mencapai tingkat akurasi 88%, secara signifikan melampaui *baseline Simple RNN* yang mengalami stagnasi representasi pada akurasi 72,83%. Lebih lanjut, arsitektur GRU mendemonstrasikan titik ekuilibrium algoritma yang superior dengan mencetak *F1-Score* tertinggi sebesar 0,895 sekaligus mereduksi latensi pelatihan hingga 50% lebih cepat dibandingkan LSTM. Temuan komparatif ini mengkonfirmasi bahwa simplifikasi parameter sirkuit pada GRU mampu meminimalkan kompleksitas waktu dan bertindak sebagai regularisator implisit yang efektif, tanpa mendegradasi performa generalisasi model dalam mengekstraksi memori kontekstual jangka panjang pada data yang pekat akan *noise*.

**Kata kunci:** Analisis Sentimen, Arsitektur Gated, GRU, LSTM, Noise Semantik

# **BAB 1**

## **PENDAHULUAN & DEFINISI**

### **MASALAH**

#### **1.1 Topik yang Dipilih**

Proyek akhir ini secara spesifik mengimplementasikan bidang kompetensi Topik 2: RNN / GRU / LSTM (Recurrent Neural Networks). Keputusan untuk mengeksplorasi kelompok model jenis rekurensi ini didasari oleh sebuah argumen rekayasa yang fundamental, yaitu kebutuhan krusial untuk memodelkan keterkaitan urutan waktu yang melekat pada data dengan dimensi urutan berurutan. Untuk menguji batas kapabilitas matematis dari paradigma ini, domain analisis sentimen multi-kelas atas opini publik Pemilihan Presiden Indonesia 2024 pada platform Twitter dipilih sebagai sub-sistem implementasi riil.

Justifikasi teknis penetapan Topik 2 ini bersandar pada hubungan timbal balik antara karakteristik data dengan batasan struktural paradigma alternatif. Data Twitter berbahasa Indonesia informal merepresentasikan bentuk data tidak terstruktur (unstructured data) yang penuh akan high-dimensional noise yang ekstrem. Fenomena linguistik ini mencakup ambiguitas struktur kalimat, pergeseran semantik akibat sarkasme politik yang mampu membalikkan kategori sentimen di akhir sekuens, fragmentasi kata berupa slang, hingga pemotongan kata atau penyingkatan kalimat. Karakteristik anomali yang pekat tersebut menciptakan risiko reduksi informasi yang signifikan jika diselesaikan menggunakan pendekatan statistik konvensional seperti bag-of-words, ataupun arsitektur non-sekuensial seperti Convolutional Neural Network (Topik 1) yang kapabilitas operasionalnya terisolasi dalam fixed-size receptive field dari konvolusi lokal, sehingga gagal menangkap relasi semantis lintas urutan jika kata kunci sentimen terpisah melampaui ukuran kernel.

Meskipun arsitektur berbasis self-attention seperti Transformer (Topik 4) menawarkan keunggulan dalam pemrosesan paralel, penerapannya pada proyek akhir ini tidak efisien karena menuntut volume data berskala masif untuk konvergensi optimal serta konsumsi memori kuadrat terhadap panjang sekuens, yang tidak kompatibel dengan batasan spesifikasi perangkat keras komputer kelompok kami. Sebaliknya, paradigma rekurens menyediakan internal memory state yang beroperasi secara inheren searah dengan jarum propagasi teks, menjadikannya arsitektur yang paling rasional untuk mempertahankan persistensi memori kontekstual jangka panjang (long-term dependencies). Dengan demikian, pemilihan Topik 2 ini menjadi konklusif sebagai instrumen untuk mengevaluasi secara empiris sejauh mana mekanika penapisan informasi internal (gating mechanism) pada model jenis rekurensi mampu memitigasi masalah hilangnya informasi penting model di tengah pekatnya noise bahasa informal.

#### **1.2 Rumusan Masalah**

Berdasarkan latar belakang pemilihan arsitektur sekuensial di atas, rumusan masalah dalam proyek tugas akhir ini difokuskan pada tiga poin utama, yaitu:

- RM1: Bagaimana perbandingan performa metrik (Akurasi dan F1-Score) antara model baseline (Simple RNN) dengan arsitektur bermekanisme gate (Bidirectional LSTM dan GRU) dalam menangkap konteks teks berbahasa Indonesia?

- RM2: Sejauh mana implementasi Bidirectional layer dan penerapan pembobotan kelas (class weight) mampu mengatasi anomali distribusi data yang tidak seimbang (imbalanced data) pada dataset opini Pilpres 2024?
- RM3: Arsitektur manakah di antara Bidirectional LSTM dan GRU yang mampu memberikan titik trade-off terbaik antara latensi komputasi (waktu training) dan kapabilitas prediksi?

### 1.3 Tujuan Proyek

T1. Membangun sistem klasifikasi sentimen publik terhadap calon presiden Indonesia 2024 menggunakan data Twitter.

T2. Membandingkan performa tiga arsitektur Recurrent Neural Network, yaitu Simple RNN, Bidirectional LSTM, dan Bidirectional GRU.

T3. Menganalisis kemampuan masing-masing model dalam memahami konteks teks sekuensial pada data sentimen.

T4. Menentukan model terbaik berdasarkan metrik evaluasi seperti Accuracy, Precision, Recall, F1-Score, dan Confusion Matrix.

T5. Mengevaluasi efektivitas preprocessing teks dan tokenisasi dalam meningkatkan kualitas data sebelum training model.

T6. Menguji pengaruh penerapan class weight untuk mengatasi ketidakseimbangan distribusi kelas sentimen.

T7. Mengevaluasi penggunaan regularisasi Dropout dan EarlyStopping dalam mengurangi overfitting pada model deep learning.

T8. Menganalisis hasil eksperimen dan perbedaan performa antar model RNN, LSTM, dan GRU pada klasifikasi sentimen bahasa Indonesia.

### 1.4 Ruang Lingkup & Batasan

Dalam menjamin validitas parameter komparasi antar-model serta mengurangi risiko pembengkakan cakupan rekayasa (scope creep), proyek akhir ini menetapkan batasan operasional dan ruang lingkup sistem melalui tiga pilar konstrain teknis berikut:

- Batasan Data dan Pipeline Preprocessing:  
Pemodelan komputasi difokuskan pada tugas klasifikasi sentimen berbasis data Twitter terkait opini publik Pemilihan Presiden Indonesia 2024. Dataset yang digunakan bersifat statis dengan total 29.728 baris data hasil penggabungan dataset Anies Baswedan, Ganjar Pranowo, dan Prabowo Subianto dari Kaggle. Label klasifikasi terdiri dari dua kelas sentimen, yaitu Positive dan Negative. Tahap preprocessing teks dibatasi pada pendekatan rule-based cleaning menggunakan Regular Expression (Regex) melalui fungsi `clean_text` yang mencakup case folding, penghapusan URL, mention (@username), hashtag (#), tanda baca, angka, serta whitespace stripping. Pipeline preprocessing tidak mencakup normalisasi bahasa informal, stemming, lemmatization, maupun pemrosesan emoji, sehingga variasi bahasa nonformal tetap dipertahankan sebagai bagian dari noise alami pada data media sosial.
- Parameterisasi Model dan Representasi Vektor:  
Representasi teks ke dalam bentuk numerik dilakukan menggunakan Keras Tokenizer dengan batas maksimum vocabulary sebesar 10.000 kata dan maximum sequence length sebesar 100 token menggunakan mekanisme padding dan truncating. Pada tahap representasi kata, proyek ini menggunakan Embedding Layer bawaan TensorFlow/Keras tanpa memanfaatkan pre-trained embedding eksternal seperti Word2Vec, GloVe, ataupun FastText. Dengan demikian, seluruh

representasi vektor dipelajari secara mandiri (learned from scratch) berdasarkan distribusi data training. Arsitektur model yang dibandingkan terdiri dari Simple RNN, LSTM, dan GRU dengan hidden units sebesar 64 neuron serta penggunaan dropout dan recurrent dropout sebesar 0.2 untuk mengurangi risiko overfitting.

- **Konstrain Eksperimen dan Evaluasi:**

Eksperimen dilakukan sebagai studi komparatif baseline untuk mengevaluasi performa ketiga arsitektur recurrent neural network. Proses training dibatasi sebanyak 5 epoch dengan batch size sebesar 64 dan validation split sebesar 0.1 menggunakan akselerasi GPU Google Colab. Dataset dibagi menggunakan rasio 80% data training dan 20% data testing dengan metode stratified split untuk menjaga distribusi kelas. Evaluasi performa model dilakukan menggunakan metrik Accuracy, Precision, Recall, F1-Score, serta Confusion Matrix. Pada tahap ini, proyek belum mencakup optimasi hiperparameter skala besar, eksplorasi berbagai optimizer, ensemble learning, maupun fine-tuning lanjutan terhadap arsitektur model.

## BAB 2

### PENDEKATAN AI

#### 2.1 Tinjauan Pustaka (*Related Work*)

*Tabel 2.1: Ringkasan tinjauan pustaka*

| Penulis (Th.)                                     | Metode                                                    | Dataset                                                        | Hasil                                                                                                                                            | Keterbatasan                                                                                                                           |
|---------------------------------------------------|-----------------------------------------------------------|----------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------|
| Hochreiter & Schmidhuber (1997) [1]               | Long Short-Term Memory (LSTM)                             | Berbagai benchmark sintetik mandiri (sekuens panjang)          | Membuktikan secara matematis dan empiris bahwa cell state dan gerbang memori berhasil memitigasi anomali vanishing gradient pada Simple RNN.     | Kompleksitas sirkuit (memiliki tiga gerbang) menghasilkan parameter komputasi yang berat dan membutuhkan waktu konvergensi lebih lama. |
| Cho et al. (2014) [2];<br>Chung et al. (2014) [3] | Gated Recurrent Unit (GRU) & Evaluasi Empiris Model Gated | Machine translation (WMT'14) dan data audio (Polyphonic music) | Menunjukkan bahwa GRU (dengan dua gerbang) mampu mencapai performa sebanding atau lebih baik dari LSTM dengan beban komputasi yang lebih ringan. | Evaluasi masih berfokus pada dataset formal standar bahasa Inggris dan audio, belum menyentuh domain teks non-formal bersentimen.      |
| Greff et al. (2016) [4]                           | LSTM: A Search Space Odyssey (Komparasi Varian)           | TIMIT (Speech recognition), dan benchmark sekuens lainnya      | Menemukan bahwa arsitektur dasar LSTM (beserta forget gate) tetap memberikan titik optimal tanpa memerlukan modifikasi internal yang rumit.      | Tidak secara spesifik membahas penanganan anomali ketidakseimbangan kelas (class imbalance) pada skenario klasifikasi biner.           |
| Wilie et al. (2020) [5]                           | IndoBERT (Transformer)                                    | IndoNLU Benchmark                                              | State-of-the-art (SOTA) untuk tugas NLU Indonesia.                                                                                               | Kebutuhan komputasi sangat berat (GPU tinggi), kurang efisien untuk deployment ringan.                                                 |

Literatur di atas merupakan karya fundamental yang memvalidasi superioritas mekanisme penapisan (gating) pada LSTM dan GRU dalam mempertahankan long-term dependencies dibandingkan arsitektur RNN konvensional. Namun, evaluasi pada literatur tersebut difokuskan pada teks formal, terjemahan mesin, atau pemrosesan sinyal. Sementara itu, Wilie et al. (2020) melalui IndoNLU memperluas landasan evaluasi NLP ke konteks Bahasa Indonesia, namun masih berada pada level benchmarking

umum dan belum secara spesifik mengeksplorasi analisis sentimen opini politik media sosial dengan ketidakseimbangan kelas yang tinggi. Proyek ini memposisikan diri untuk menjembatani teori fundamental tersebut ke dalam domain praktis yang memiliki tantangan spesifik: analisis sentimen opini publik media sosial (Pilpres Indonesia 2024). Berbeda dengan pengujian standar pada pustaka di atas, proyek ini mengungguli model baseline dengan membungkus sel LSTM dan GRU menggunakan Bidirectional layer untuk memahami konteks kalimat bahasa informal dua arah (maju dan mundur). Lebih lanjut, proyek ini secara langsung menutupi celah keterbatasan eksperimen fundamental sebelumnya dengan mengintegrasikan kompensasi parameter `class_weight` untuk menjinakkan anomali ketidakseimbangan kelas ekstrem (21.654 sampel Positif vs 8.074 sampel Negatif) yang sering mendistorsi objektivitas model.

## 2.2 Landasan Teori Model yang Dipilih

Pemrosesan bahasa alami (Natural Language Processing) untuk analisis sentimen berhadapan dengan data teks yang direpresentasikan sebagai data sekuensial berdimensi waktu. Untuk mengakomodasi urutan temporal ini, proyek ini mengimplementasikan keluarga arsitektur Recurrent Neural Network (RNN).

### 1. Simple Recurrent Neural Network (RNN)

Berbeda dengan jaringan saraf feed-forward biasa, RNN memproses data sekuensial dengan mengalirkan representasi status tersembunyi (hidden state) dari langkah waktu (time-step) sebelumnya ke langkah waktu saat ini. Namun, arsitektur dasar RNN memiliki batasan fatal berupa vanishing gradient. Saat proses pembaruan bobot (backpropagation through time) melintasi sekuens kalimat yang panjang, nilai gradien menyusut secara eksponensial hingga mendekati nol. Hal ini mengakibatkan RNN gagal menangkap long-term dependencies atau konteks kata yang posisinya berada di awal kalimat.

### 2. Long Short-Term Memory (LSTM)

Untuk memitigasi anomali hilangnya gradien tersebut, proyek ini menggunakan arsitektur LSTM yang diusulkan oleh Hochreiter dan Schmidhuber (1997). Inovasi utama LSTM adalah keberadaan jalur cell state ( $C_t$ ) yang memungkinkan informasi mengalir secara langsung tanpa banyak interaksi linear. Regulasi informasi masuk dan keluar pada memori ini dikendalikan oleh tiga gerbang (gates): forget gate, input gate, dan output gate.

Persamaan matematis kunci pada forget gate, yang bertugas memutuskan persentase informasi masa lalu mana yang harus dibuang atau dipertahankan dari cell state, didefinisikan sebagai:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.1)$$

### 3. Gated Recurrent Unit (GRU)

Sebagai model komparatif utama, eksperimen ini juga mengevaluasi GRU. Arsitektur yang dikembangkan oleh Cho et al. (2014) dan Chung et al. (2014) ini merupakan modifikasi efisien dari LSTM. GRU menyederhanakan sirkuit dengan menggabungkan forget gate dan input gate menjadi satu update gate ( $z_t$ ), serta melebur cell state dan hidden state ke dalam satu dimensi aliran data. Persamaan matematis kunci untuk update gate pada GRU (yang mengevaluasi seberapa banyak informasi masa lalu yang perlu diteruskan ke masa depan) adalah:


$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \quad (2.2)$$

Simplifikasi pengurangan gerbang ini secara langsung memangkas jumlah beban komputasi

parameter, menjadikan GRU berpotensi mengeksekusi proses pelatihan secara lebih cepat dengan daya representasi yang setara dengan LSTM.

#### 4. Mekanisme Representasi Dua Arah (Bidirectional)

Untuk mengoptimalkan pemahaman konteks pada bahasa informal di Twitter, arsitektur memori di atas dibungkus dengan integrasi Bidirectional layer. Dalam topologi ini, input disalurkan ke dalam dua lapisan rekuren yang independen: satu lapisan memproses teks maju (forward sequence dari kiri ke kanan), sementara lapisan kedua memproses teks secara terbalik (backward sequence dari kanan ke kiri). Keluaran dari kedua lintasan tersebut kemudian digabungkan (melalui proses concatenation), memberikan model kapabilitas inferensi semantik secara utuh sebelum mengeksekusi prediksi label klasifikasi akhir.



Gambar 2.1: Arsitektur struktur sirkuit sel memori LSTM (a) dan GRU (b) beserta skema gating mechanism. (Sumber: Chung et al., 2014 [3])

## 2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI

Pemilihan arsitektur jaringan saraf rekuren berbasis gerbang (gated recurrent neural networks) dalam proyek ini didasarkan pada analisis teoritis dan konstrain praktis yang matang. Bagian ini membedah justifikasi ilmiah tersebut berdasarkan tiga pilar utama: komparasi terhadap arsitektur alternatif, analisis trade-off multi-parameter, dan kesesuaian terhadap karakteristik domain data.

### 1. Pemilihan Keluarga Arsitektur vs Alternatif Lain (CNN & Transformer)

Dalam pemrosesan bahasa alami (Natural Language Processing), terdapat tiga keluarga besar arsitektur yang sering digunakan: Convolutional Neural Networks (CNN), Transformers, dan Recurrent Neural Networks (RNN) beserta variannya.

- Kelemahan CNN untuk Teks: Pendekatan spasial seperti CNN mengandalkan ukuran jendela lokal (kernel size) untuk menangkap hubungan antar kata (n-grams). Meskipun proses komputasinya cepat karena dapat di paralelisasi, CNN tidak memiliki mekanisme memori sekuensial bawaan untuk menelusuri hubungan ketergantungan jarak jauh (long-term dependencies) yang mengalir di sepanjang kalimat.
- Kelemahan Transformer: Di sisi lain, arsitektur berbasis Self-Attention seperti Transformers (misalnya IndoBERT) menawarkan performa canggih, namun memiliki trade-off berupa jumlah parameter yang sangat masif, kebutuhan memori GPU yang tinggi, serta kerentanan mengalami overfitting yang ekstrem jika dilatih dari awal (from scratch) atau di-fine-tune pada dataset berukuran menengah (29.728 sampel) tanpa dukungan infrastruktur komputasi skala besar.
- Keunggulan Sirkuit Rekuren Gated: Oleh karena itu, keluarga RNN dengan mekanisme penapisan informasi (gating mechanism) dipilih sebagai jalan tengah terbaik. Arsitektur ini secara alami memproses token teks langkah-demi-langkah dengan mengalirkan status tersembunyi (hidden state), sehingga mampu memetakan representasi semantik temporal secara mandiri dari awal tanpa harus bergantung pada bobot eksternal (pre-trained embeddings) yang berat.

### 2. Analisis Trade-off Komputasi dan Prediksi (Akurasi vs Kecepatan vs Ukuran Model)

Eksperimen komparatif yang dikonstruksi dalam proyek ini membuktikan adanya trade-off nyata antara kompleksitas sirkuit internal model dengan efisiensi komputasi yang dihasilkan:

- Simple RNN (Baseline): Memiliki ukuran parameter paling kecil dan waktu pelatihan paling instan, yaitu hanya 44,15 detik. Namun, akibat masalah hilangnya gradien (vanishing gradient), daya tampung memorinya hancur, menghasilkan stagnasi performa dengan F1-Score rendah sebesar 0,6139.
- Bidirectional LSTM (Proposed): Dengan menambahkan cell state dan tiga gerbang internal (forget, input, output gate), LSTM berhasil melompati keterbatasan baseline dan mencetak F1-Score tinggi sebesar 0,8906. Meskipun demikian, kompleksitas sirkuit ini mengorbankan sisi efisiensi komputasi secara masif, memaksa waktu pelatihan membengkak hingga 980,28 detik.
- Bidirectional GRU (Proposed): GRU menawarkan titik ekuilibrium (trade-off terbaik) dengan memangkas sirkuit menjadi dua gerbang saja (update dan reset gate). Secara teoritis dan empiris, penyederhanaan sirkuit ini bertindak sebagai regularisator implisit yang efektif untuk menekan risiko overfitting. Hasil eksperimen menunjukkan bahwa GRU mampu mencetak F1-Score yang relatif tinggi sebesar 0,8735 sekaligus memotong latensi waktu pelatihan hingga 414,71 detik (hampir 60% lebih cepat dibandingkan LSTM).

### 3. Konteks Domain yang Membuat Pilihan Ini Superior


Domain data yang dihadapi adalah teks opini media sosial Twitter terkait konstelasi politik Pilpres 2024. Teks pada domain ini memiliki karakteristik noise semantik yang sangat pekat, dicirikan oleh fragmentasi kata, penggunaan bahasa informal, singkatan, serta tingginya intensitas kalimat sarkasme maupun negasi.

Dalam struktur kebahasaan seperti ini, satu token penentu sentimen yang berada di awal kalimat (misalnya kata negasi seperti "tidak" atau "belum") dapat membalikkan seluruh polaritas makna dari rangkaian kata panjang yang mengikutinya di ujung kalimat. Integrasi komponen Bidirectional layer pada LSTM dan GRU menjadi krusial karena model dipaksa membaca teks melalui dua arah secara simultan: sekuens maju (forward) dan sekuens mundur (backward). Mekanisme dua arah inilah yang memberikan konteks semantik utuh kepada model sebelum keputusan klasifikasi biner diambil, menjadikannya jauh lebih unggul dalam mengenali pola sarkasme politik dibandingkan model linear konvensional.

## 2.4 *Block Diagram Sistem End-to-End*

Sistem klasifikasi sentimen pada proyek ini dirancang melalui arsitektur pipeline end-to-end yang memproses data mentah menjadi keputusan prediksi secara sekuensial. Alur sistem ini dibagi menjadi lima tahapan utama:

1. Tahap Masukan (Data Input): Sistem menerima masukan berupa korpus teks (dataset) opini publik Twitter terkait Pilpres 2024 yang berisi 29.728 sampel dengan dua label aktual (ground truth), yaitu sentimen Positif dan Negatif.
2. Tahap Pra-pemrosesan (Preprocessing): Teks mentah disalurkan ke dalam modul pembersihan berbasis reguler ekspresi (Regex) untuk membuang noise (seperti URL, mention, hashtag, tanda baca, dan angka). Teks bersih tersebut kemudian di tokenisasi ke dalam bentuk representasi numerik (dengan batas vocabulary 10.000 kata) dan diseragamkan panjang sekuensnya (padding) hingga 100 token agar dapat diproses oleh matriks jaringan saraf.
3. Tahap Pemodelan (Model Architecture): Vektor input dipetakan ke dalam ruang semantik berdimensi padat melalui Embedding Layer. Fitur temporal kemudian diekstraksi secara sekuensial oleh arsitektur baseline (Simple RNN) atau model utama (Bidirectional LSTM / Bidirectional GRU). Sirkuit ini juga melewati lapisan Dropout (0.2) untuk mengurangi risiko overfitting sebelum bermuara pada Dense Layer sebagai pengambil keputusan akhir.
4. Tahap Fungsi Objektif (Loss & Optimization): Selama fase training, sistem menghitung galat prediksi menggunakan fungsi objektif Sparse Categorical Cross Entropy yang dioptimasi oleh algoritma Adam. Pada tahap ini, anomali ketidakseimbangan kelas ditangani dengan menyuntikkan parameter `class_weight` ke dalam perhitungan loss, sehingga model memberikan penalti yang lebih besar saat gagal memprediksi kelas minoritas.
5. Tahap Evaluasi & Keluaran (Metrics & Output): Sistem mengevaluasi kinerja training dan inferensi menggunakan metrik Accuracy, Precision, Recall, dan F1-Score. Keluaran akhir (output) dari pipeline ini adalah probabilitas prediksi label sentimen untuk setiap teks pada fase pengujian.




Gambar 2.2: Block diagram sistem yang diusulkan

## 2.5 Flowchart Program

Alur runtime program dalam proyek ini dikonstruksikan untuk memastikan efisiensi eksperimen dan reproduktibilitas hasil. Program berjalan melalui dua fase utama: fase Training untuk mempelajari pola sentimen, dan fase Inference (pengujian) untuk melakukan prediksi pada data baru.

1. **Fase Inisialisasi:** Program dimulai dengan pengunduhan dataset dari Kaggle, diikuti dengan pembacaan dan penggabungan dataset menggunakan Pandas DataFrame.
2. **Fase Pra-pemrosesan:** Teks mentah melewati fungsi `clean_text` untuk pembersihan noise (Regex), diikuti dengan tokenization dan padding menjadi sekuens berukuran 100.
3. **Fase Pelatihan (Training):** Data dibagi menjadi train, validation, dan test set. Model (RNN/LSTM/GRU) dibangun dengan parameter embedding dan dropout 0.2. Proses training dijalankan dengan menyuntikkan `class_weight` dan memantau EarlyStopping berbasis `val_loss` untuk menghindari overfitting.
4. **Fase Evaluasi & Inferensi:** Setelah model mencapai kondisi optimal, dilakukan evaluasi pada test set menggunakan metrik performa (Accuracy, Precision, Recall, F1-Score). Hasil akhir berupa klasifikasi sentimen biner (Positif/Negatif) ditampilkan dalam bentuk Confusion Matrix dan grafik kurva pembelajaran.



Gambar 2.3: Flowchart program training dan inference

## BAB 3

### IMPLEMENTASI & HASIL EKSPERIMEN

#### 3.1 Dataset & Pra-pemrosesan

Guna menjamin transparansi, akuntabilitas, dan keterukuran manajemen rekayasa perangkat lunak, seluruh rangkaian aktivitas proyek akhir dipetakan secara kronologis sejak penugasan dimulai pada tanggal 4 Mei 2026 hingga pelaporan progres aktual pada tanggal 25 Mei 2026. Dokumentasi ini disusun untuk menggambarkan perkembangan implementasi sistem analisis sentimen berbasis Deep Learning secara terstruktur, mulai dari tahap akuisisi data hingga evaluasi performa model.

Tabel 3.1 berikut menyajikan ringkasan status operasional dan dekonstruksi aktivitas dari setiap tahapan pekerjaan kelompok.

*Tabel 3.1: Status per tahapan pekerjaan*

| Tahap                 | Aktivitas                                                                                                                                                                                                        | Status |
|-----------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------|
| Pencarian dataset     | Mengakuisisi, memverifikasi, dan mengarsip dataset opini publik Pilpres 2024 dari platform Kaggle yang berisi data tweet berlabel sentimen pasangan calon presiden Indonesia 2024.                               | ✓      |
| EDA & pra-pemrosesan  | Implementasi fungsi preprocessing deterministik meliputi case folding, penghapusan URL, mention, hashtag, angka, simbol, whitespace normalization, serta tokenisasi teks menggunakan Tokenizer TensorFlow/Keras. | ✓      |
| Tokenisasi & encoding | Transformasi data teks menjadi representasi numerik menggunakan sequence padding, label encoding, serta penerapan class weighting untuk menangani ketidakseimbangan distribusi kelas sentimen.                   | ✓      |
| Implementasi model    | Konstruksi arsitektur sekuensial modular untuk tiga varian model komparasi intrinsik (RNN, LSTM, dan GRU) memanfaatkan TensorFlow/Keras.                                                                         | ✓      |
| Training awal         | Pelaksanaan pelatihan awal model menggunakan parameter baseline berupa batch size 64, validation split 0.1, optimizer Adam, serta evaluasi awal performa antar-model.                                            | ✓      |
| Pengembangan          | Implementasi mekanisme regularisasi                                                                                                                                                                              | ✓      |

|                         |                                                                                                                                                                                                                            |   |
|-------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---|
| arsitektur              | dan optimasi model melalui penambahan Dropout Layer, Bidirectional Layer, dan EarlyStopping callback guna meningkatkan stabilitas generalisasi model.                                                                      |   |
| Evaluasi & metrik       | Perhitungan metrik performa model meliputi Accuracy, Precision, Recall, F1-Score, confusion matrix, serta pengukuran waktu pelatihan masing-masing model.                                                                  | ✓ |
| Visualisasi hasil       | Pembuatan grafik perbandingan validation accuracy, validation loss, dan confusion matrix menggunakan Matplotlib dan Seaborn untuk mendukung interpretasi performa model.                                                   | ✓ |
| Hyperparameter tuning   | Eksplorasi lanjutan terhadap ruang parameter seperti jumlah hidden units, konfigurasi recurrent layer, learning configuration, dan variasi optimizer untuk memperoleh performa optimal.                                    | ✓ |
| Error analysis          | Analisis distribusi kesalahan klasifikasi berdasarkan confusion matrix guna mengidentifikasi pola bias prediksi dan karakteristik misclassification antar kelas sentimen.                                                  | ✓ |
| Penulisan laporan akhir | Penyusunan dan finalisasi keseluruhan laporan teknis proyek meliputi Bab 1 (Pendahuluan), Bab 2 (Tinjauan Pustaka), Bab 3 (Metodologi dan Implementasi), Bab 4 (Hasil dan Pembahasan), serta Bab 5 (Kesimpulan dan Saran). | ✓ |

---

## 3.2 Konfigurasi Eksperimen

Konfigurasi eksperimen disusun untuk memastikan proses pelatihan model berjalan secara konsisten, terukur, dan dapat direproduksi. Penentuan hyperparameter dilakukan berdasarkan kombinasi antara konfigurasi standar yang umum digunakan pada model klasifikasi teks berbasis deep learning serta proses hyperparameter tuning terbatas guna memperoleh performa model yang lebih optimal. Beberapa parameter utama yang dikonfigurasi meliputi learning rate, batch size, jumlah epoch, optimizer, fungsi loss, hingga penggunaan mekanisme early stopping untuk mencegah terjadinya overfitting selama proses training. Rincian konfigurasi hyperparameter yang digunakan pada penelitian ini ditunjukkan pada Tabel 3.2 berikut.

*Tabel 3.2: Hyperparameter eksperimen*

| Hyperparameter | Nilai                                                                                                                           |
|----------------|---------------------------------------------------------------------------------------------------------------------------------|
| Learning rate  | 0.001 (nilai bawaan fungsi Adam) untuk base model , serta diuji pada angka 0.001 dan 0.0005 saat tahapan hyperparameter tuning. |
| Batch size     | 64                                                                                                                              |
| Epoch          | 10 (dengan menggunakan Early Stopping patience=3). Untuk tuning, dicoba dengan 5 epoch.                                         |
| Optimizer      | Adam.                                                                                                                           |
| Scheduler      | Tidak menggunakan Learning Rate Scheduler (Hanya menggunakan callback EarlyStopping).                                           |
| Loss function  | sparse_categorical_crossentropy                                                                                                 |
| Random seed    | 10 (Digunakan pada random_state saat pembagian data dan np.random.seed saat tuning).                                            |

### 3.3 Metrik Evaluasi

Pada eksperimen analisis sentimen ini, evaluasi performa model tidak hanya mengandalkan metrik Accuracy, melainkan menggunakan beberapa metrik yang lebih komprehensif mengingat distribusi kelas pada dataset yang tidak seimbang (imbalanced), yakni kelas Positive (21.654 sampel) jauh mendominasi dibandingkan kelas Negative (8.074 sampel). Berikut adalah metrik yang dievaluasi beserta justifikasinya:

1. F1-Score (Weighted): Merupakan metrik utama yang dijadikan tolok ukur penentu performa terbaik model. F1-Score adalah rata-rata harmonis dari Precision dan Recall. Metode weighted average dipilih secara spesifik karena dataset bersifat imbalanced. Melalui metode ini, metrik dihitung untuk setiap kelas secara independen, lalu dirata-ratakan dengan memberikan bobot proporsional berdasarkan jumlah sampel (support) masing-masing kelas. Hal ini mencegah model terlihat bagus hanya karena menebak kelas mayoritas.
2. Precision & Recall (Weighted): Precision digunakan untuk melihat seberapa presisi model dalam memprediksi label yang benar (meminimalkan False Positive), sementara Recall melihat seberapa peka model menemukan seluruh sampel positif/negatif yang ada (meminimalkan False Negative). Sama seperti F1-Score, keduanya dievaluasi menggunakan metode weighted agar representatif terhadap kelas minoritas.
3. Accuracy: Digunakan sebagai gambaran umum persentase tebakan yang benar dari total keseluruhan data pengujian. Namun, akurasi hanya dijadikan parameter pendukung (evaluasi sekunder) untuk memvalidasi bahwa model benar-benar belajar dari kedua kelas, bukan sekadar terjebak pada ilusi akurasi kelas mayoritas.
4. Confusion Matrix: Digunakan sebagai metrik visual untuk menganalisis pola kegagalan atau misklasifikasi model secara spesifik (True Positive, False Positive, True Negative, False Negative), sehingga terlihat jelas kelas mana yang paling sering tertukar (error rate).

### 3.4 Hasil Kuantitatif

Tabel 3.3: Hasil kuantitatif model

|            | Accuracy | Precision | Recall   | F1-Score | Training Time (s) |
|------------|----------|-----------|----------|----------|-------------------|
| Simple RNN | 0.728389 | 0.53055   | 0.728389 | 0.613925 | 21.839069         |
| LSTM       | 0.888833 | 0.894358  | 0.888833 | 0.890631 | 980.282315        |
| GRU        | 0.871174 | 0.878069  | 0.871174 | 0.873466 | 414.716151        |

Hasilnya menunjukkan LSTM dan GRU sudah mencapai **akurasi sekitar 88%**, sementara Simple RNN masih tertinggal di 72%. Hal ini membuktikan arsitektur **gating** (LSTM dan GRU) jauh lebih mampu menangkap pola teks.

Menariknya lagi, GRU **mampu menyaingi LSTM** di F1-Score dan akurasi dengan waktu training yang sekitar **50% lebih cepat** dibanding LSTM. Jadi kalau ditanya efisiensi vs performa, **GRU** terlihat sebagai pilihan **paling optimal** di sini.

### 3.5 Analisis Hyperparameter Tuning


Proses optimasi *hyperparameter* dilakukan menggunakan metode Random Search dibandingkan *Grid Search* penuh. Keputusan ini diambil berdasarkan justifikasi efisiensi komputasional, mengingat eksplorasi kombinasi secara menyeluruh (*exhaustive search*) pada arsitektur *Recurrent Neural Network* (RNN) memakan beban waktu pelatihan (*training time*) yang eksponensial. Optimasi difokuskan pada arsitektur Bidirectional GRU, yang terpilih sebagai *baseline* terbaik pada fase *training* awal dengan skor F1 mencapai 0.8919.

Ruang pencarian (*search space*) didefinisikan pada empat *hyperparameter* kunci:

1. Dimensi *Embedding* (*embedding\_dim*): [64, 128, 256]
2. Jumlah *Hidden Units* (*units*): [64, 128, 256]
3. Tingkat Regularisasi (*dropout*): [0.2, 0.3, 0.5]
4. *Learning Rate* (*learning\_rate*): [0.001, 0.0005] menggunakan *optimizer* Adam.

Diskusi Sensitivitas Hyperparameter: Berdasarkan dokumentasi *trial* eksperimen (misalnya Trial 1 dengan parameter *units*=128, *dropout*=0.3, *embedding\_dim*=64, dan *lr*=0.0005), *hyperparameter* yang teramati paling sensitif terhadap stabilitas konvergensi model adalah Learning Rate dan Dropout. Penurunan *learning rate* ke angka 0.0005 memitigasi osilasi *loss* yang agresif dan mencegah model terjebak pada *local minima* selama proses optimasi *stochastic gradient descent*. Sementara itu, peningkatan tingkat *dropout* di atas 0.3 cenderung menyebabkan *underfitting* akibat terlalu banyak neuron yang dieliminasi secara acak selama propagasi, sedangkan *dropout* yang terlalu rendah (<0.2) mempercepat *overfitting* yang terlihat dari pelebaran jarak antara *training loss* dan *validation loss*.

### 3.6 Hasil Kualitatif & Error Analysis



Gambar 3.1 Confusion Matrix dari komparasi prediksi model Simple RNN, LSTM, dan GRU terhadap data pengujian.

Berdasarkan hasil Confusion Matrix di atas, dilakukan analisis berdasarkan keterbatasan penggunaan model ini:

#### 1. Keterbatasan Data & Preprocessing

- Hapus hashtag dan mention: Informasi kontekstual penting seringkali terkandung dalam hashtag (misal: #DebatCapres). Penghapusan menyebabkan kehilangan konteks.
- Case folding: Penulisan huruf kapital dalam bahasa Indonesia sering digunakan untuk penekanan emosi (misal: "SANGAT KECEWA"). Mengubah ke lowercase menghilangkan sinyal ini.
- Tidak ada handling sarkasme/ironi: Model RNN/LSTM standar sulit mendeteksi sarkasme yang sangat umum di media sosial.
- OOV (Out-of-Vocabulary): Kata-kata slang, typo, atau bahasa daerah tidak ada di vocabulary (diubah menjadi <OOV>), mengurangi akurasi.

#### 2. Potensi Bias

- Bias kandidat: Jika dataset per kandidat memiliki distribusi sentimen yang sangat berbeda, model mungkin belajar bias politik tertentu.
- Bias bahasa: Model hanya dilatih pada teks Indonesia. Campuran bahasa (Indonesia-Inggris) atau bahasa daerah tidak ditangani dengan baik.
- Bias temporal: Data berasal dari periode tertentu (kampanye Pilpres 2024). Sentimen dapat berubah drastis setelah periode tersebut.

#### 3. Edge Cases yang Perlu Diwaspadai

- Teks sangat pendek: Tweet dengan 1-2 kata (misal: "mantap", "gak setuju") sulit diklasifikasikan karena kurangnya konteks.
- Teks ambigu: Kalimat netral yang mengandung kata-kata positif/negatif (misal: "saya tidak suka tapi saya menghargai").
- Teks provokatif/bukan opini: Tweet yang berisi hoaks atau provokasi bukanlah ekspresi sentimen genuine, tapi model tetap akan mengklasifikasikannya.
- Akun bot/spam: Jika dataset mengandung tweet dari akun bot, model belajar dari data yang tidak merepresentasikan opini manusia asli.

#### 4. Implikasi Etis Penggunaan

- Representasi publik yang tidak adil: Model ini tidak boleh digunakan sebagai dasar kebijakan tanpa validasi manual karena tingkat error yang masih signifikan.
- Privasi: Meskipun data publik, penggunaan sentimen analisis untuk profiling individu tanpa consent bermasalah secara etis.
- Amplifikasi bias: Jika digunakan untuk memantau opini publik secara otomatis, model bisa memperkuat bias yang sudah ada dalam dataset.
- Akuntabilitas: Kesalahan klasifikasi pada level individu dapat merugikan reputasi

seseorang.



Gambar 3.2 Error Rate per Kelas Sentimen

### 3.7 Pembahasan

Eksperimen ini berhasil memvalidasi secara empiris superioritas arsitektur dengan mekanisme *gated* (LSTM dan GRU) atas Simple RNN standar dalam pemrosesan *Natural Language Processing* (NLP). Model Bidirectional LSTM dan GRU mampu menembus skor metrik di atas 88% - 89%, sedangkan Simple RNN mengalami kegagalan fatal (terjebak memprediksi kelas mayoritas secara absolut dengan F1-Score hanya di kisaran 11% dan akurasi 27%). Kegagalan Simple RNN ini disebabkan oleh masalah fundamental *Vanishing Gradient* pada pemrosesan sekuensial, dimana propagasi mundur (*backpropagation*) kehilangan nilai gradiennya di langkah-langkah awal. Sebaliknya, *update gate* dan *forget gate* pada GRU/LSTM terbukti secara matematis mampu mempertahankan dependensi jangka panjang (*long-term dependencies*) dalam kalimat komposit data Twitter politik.

Pencapaian metrik akurasi stabil di angka 88% (*validation accuracy*) menggunakan ekstraksi vektor dimensi rendah (128 dimensi) setara, dan bahkan dalam beberapa kasus lebih baik, jika dibandingkan dengan literatur *baseline* sentimen analisis konvensional menggunakan algoritma pembelajaran mesin tradisional (seperti *Support Vector Machine* atau *Naive Bayes* dengan ekstraksi TF-IDF) pada data berbahasa Indonesia. Capaian ini menunjukkan optimasi pembobotan kelas (*balanced class weight*) sukses memitigasi bias pada dataset yang sangat timpang (*Positive*: 21.654, *Negative*: 8.074). Meski demikian, performa ini diproyeksikan masih berada sedikit di bawah *State-of-the-Art* (SOTA) literatur modern yang mengimplementasikan arsitektur *Large Language Models* (*Pre-trained Transformers*), karena keterbatasan model generik dalam menangkap pemahaman leksikal kontekstual (seperti perbedaan makna kata tergantung konteks kalimatnya).

Studi ini tereduksi oleh beberapa faktor teknis dan data. Pertama, model dihadapkan pada *temporal bias*, data merepresentasikan opini statis selama masa krusial Pilpres 2024 dan belum tentu *robust* untuk inferensi data politik lintas periode. Kedua, absennya *handling* spesifik untuk percampuran bahasa (*Code-Mixing* Indonesia-Inggris) dan dialek daerah, yang mana merupakan prevalensi absolut pada lanskap Twitter (X) Indonesia. Ketiga, tidak adanya sistem deteksi anomali pada dataset menyebabkan opini organik bercampur dengan amplifikasi otomatis (*bot spam*), menyuntikkan *noise* ke dalam fungsi objektif model selama *training*.

## BAB 4

### PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL

#### 4.1 Bryan Herdianto – NPM. 2306210885

##### IV.1.1 Komponen yang Dikerjakan

Daftar konkret bagian proyek yang menjadi tanggung jawab penuh saya:

- **Kode/modul:** Modul Model Construction & Training Loop (Konstruksi sirkuit Keras Sequential API, inisialisasi bobot layer, penegakan random seed, dan monitoring epoch).
- **Bagian arsitektur:** Pembangunan sirkuit tiga varian model komparatif (RNN, LSTM, dan GRU) yang terintegrasi dengan regularisasi Dropout 0.2 dan Recurrent Dropout 0.2 pada lapisan tersembunyi (64 hidden units). Melakukan training tiga model komparatif dengan EarlyStopping di Google Colab. Menjalankan Google Colab dengan TPU dan training tiga model (Simple RNN, LSTM, dan GRU) untuk nanti di-compare hasilnya. Lalu, menambahkan juga penjelasan bonus edge cases dan identifikasi kenapa bisa gagal.
- **Bagian analisis:** Justifikasi teoretis performa latensi sirkuit penapis (gating mechanism) inter-model serta analisis mitigasi anomali vanishing gradient. Menulis implementasi model dan komentar singkat untuk hasil performa ketiga model.
- **Bagian laporan:** Bab 2.2 (Arsitektur Model yang Dipilih), Bab 2.3 (Justifikasi Awal Pemilihan Pendekatan), Bab 3.3 (Implementasi Model), dan Bab 3.7 (Pembahasan)

##### IV.1.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Gemini 3.1 Pro dan GitHub Copilot.
- **Untuk bagian apa:** Debugging kompatibilitas parameter internal Keras Sequential layers serta drafting markdown dalam Colab.
- **Tingkat ketergantungan:** Rendah
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

#### 4.2 Reyhan Ahnaf Deannova – NPM. 2306267100

##### IV.2.1 Komponen yang Dikerjakan

- **Kode/modul:** Modul Data Acquisition & Baseline Experiment Pipeline, meliputi implementasi pengunduhan dataset menggunakan KaggleHub API, pencarian otomatis file CSV menggunakan

os.walk, penggabungan dataset Anies Baswedan, Ganjar Pranowo, dan Prabowo Subianto menggunakan Pandas DataFrame concatenation, penanganan missing values menggunakan dropna, serta pembangunan alur awal eksperimen model klasifikasi sentimen.

- **Bagian arsitektur:** Perancangan struktur awal notebook eksperimen berbasis pipeline end-to-end yang mencakup tahap load dataset, preprocessing, tokenization, model construction, training, evaluation, dan visualization. Melakukan integrasi dataset multi-sumber ke environment Google Colab dan penyiapan data sebelum proses training model.
- **Bagian analisis:** Analisis integritas data hasil konsolidasi dataset multi-kandidat, pengecekan distribusi kelas sentimen, analisis kesiapan dataset untuk proses training dan evaluasi model, serta penyusunan tujuan proyek yang berfokus pada komparasi performa model RNN, LSTM, dan GRU dalam klasifikasi sentimen.
- **Bagian laporan:** Bab 1.4 (Ruang Lingkup & Batasan), Bab 1.3 (Tujuan Proyek), Bab 3.1 (Dataset & Akuisisi Data), Bab 3.2 (Bagian Integrasi dan Persiapan Dataset), serta kontribusi pada Konfigurasi Eksperimen.

## IV.2.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** ChatGPT dan Claude.
- **Untuk bagian apa:** Eksplorasi implementasi KaggleHub API di Google Colab, debugging proses pencarian file dataset otomatis, optimasi penggabungan dataframe Pandas, konsultasi struktur pipeline eksperimen machine learning, serta bantuan penyusunan dan perapihan deskripsi teknis pada laporan proyek.
- **Tingkat ketergantungan:** Sedang (Parafrase, ideasi, dan kode berasal dari AI dengan konsep dan alur dari diri saya sendiri)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

## 4.3 Muhammad Hilmi Al Muttaqi – NPM. 2306267082

### IV.3.1 Komponen yang Dikerjakan

- **Kode/modul:** Implementasi pipeline pra-pemrosesan teks (modul clean\_text) berbasis Regular Expression (RegEx) tingkat lanjut untuk mereduksi noise linguistik (URL, mention, hashtag, tanda baca, dan angka), serta orkestrasi integrasi Keras Tokenizer dan mekanika pad\_sequences untuk vektorisasi data.
- **Bagian arsitektur:** Perancangan dimensi penapisan input sekuensial model melalui standarisasi maximum sequence length = 100 dengan presisi zero-padding (implementasi padding='pre') untuk mencegah distorsi hidden state dan hilangnya informasi pada lapisan jaringan.
- **Bagian analisis:** Pelaksanaan Exploratory Data Analysis (EDA) untuk pemetaan sebaran frekuensi kata kunci tekstual dan identifikasi proaktif terhadap anomali ketimpangan kelas (class imbalance) pada distribusi label sentimen untuk penentuan strategi pembobotan model.
- **Bagian laporan:** Penyusunan fondasi teoritis pada Bab 1.1 (Topik yang Dipilih) dan Bab 1.2 (Rumusan Masalah), serta pendokumentasian metodologi rekayasa data (data engineering) secara

akademis pada Bab 3.2 (Implementasi Pra-pemrosesan Teks).

### IV.3.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Gemini 3.1 Pro
- **Untuk bagian apa:** Asistensi perumusan logika string kompleks pada Regular Expression (Regex) untuk data cleaning, analisis debugging arsitektur evaluasi binary classification, serta brainstorming kerangka draf awal naskah laporan pendahuluan.
- **Tingkat ketergantungan:** Sedang (Parafrase, ideasi, dan kode berasal dari AI dengan konsep dan alur dari diri pemikiran pribadi)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

## 4.4 Adhikananda Wira Januar – NPM. 2306267113

### IV.4.1 Komponen yang Dikerjakan

- **Kode/modul:** Modul Evaluation Metrics & Visualization (Implementasi skrip Sklearn classification\_report dan plotting kurva performa inter-model).
- **Bagian arsitektur:** Konstruksi lapisan klasifikasi akhir (Softmax head) berdimensi 3 serta pemetaan matriks keputusan probabilitas diskrit.
- **Bagian analisis:** Interpretasi metrik kuantitatif evaluasi inter-model, dekonstruksi anomali Majority Class Classifier Bias per kelas, dan visualisasi Confusion Matrix menggunakan library Seaborn.
- **Bagian laporan:** Bab 2.1 (Studi Literatur), Bab 3.1 (Ringkasan Status per Tahap), Bab 3.4 (Hasil Eksperimen), dan Bab 4 (Pembagian Tugas & Deklarasi).

### IV.4.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Gemini 3.1 Pro.
- **Untuk bagian apa:** Penulisan skrip visualisasi data grafik menggunakan library Seaborn/Matplotlib serta penataan sintaksis draf perbandingan teks studi literatur.
- **Tingkat ketergantungan:** Sedang
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

## BAB 5

### KESIMPULAN & PEKERJAAN LANJUTAN

#### 5.1 Kesimpulan

1. LSTM unggul tetapi paling lambat (F1-Score: LSTM 0,8906 > GRU 0,8735 > RNN 0,6139. Namun, LSTM membutuhkan 980,3 detik. Hal ini menunjukkan trade-off akurasi dan efisiensi komputasi.
2. Error rate kelas Negative (14,7%) jauh melebihi kelas Positive (9,8%) pada model LSTM terbaik, meskipun class weight sudah diterapkan.
3. Bias distribusi antar kandidat signifikan, yaitu sentimen positif mendominasi 79,22% (Ganjar), 74,34% (Prabowo), dan 64,99% (Anies), dengan selisih 14,23 poin persen antara Ganjar dan Anies yang berpotensi menurunkan generalisasi model.

#### 5.2 Klaim Bonus Skor

- ☐ B1. Evaluasi Komparatif & Iterasi → bukti pada Subbab 3.4 dan 3.5
- ☐ B2. Dataset Mandiri → bukti pada Subbab 3.1 + Lampiran B
- ☒ B3. Analisis Etika, Bias, & Keterbatasan → bukti pada Subbab 3.7

#### 5.3 Pekerjaan Lanjutan (*Future Work*)

1. **Mengganti embedding layer dengan IndoBERT pretrained model:** Embedding layer saat ini dilatih dari nol tanpa konteks bahasa. Menggunakan IndoBERT (Indonesian BERT) sebagai backbone akan menangkap semantik bahasa Indonesia, slang, dan konteks dua arah secara lebih kaya, berpotensi mengatasi error tinggi pada kelas Negative yang saat ini 14,7%.
2. **Mengevaluasi generalisasi pada dataset out-of-domain:** Model dilatih pada tweet Pilpres 2024 (Oktober 2022–April 2023). Perlu diuji pada dataset sentimen Indonesia dari domain berbeda (misal: review e-commerce Tokopedia atau opini kebijakan publik) untuk mengukur apakah model masih perform di luar domain politik.
3. **Menambahkan lapisan attention mechanism:** Menambahkan mekanisme self-attention setelah layer recurrent agar model dapat memberi bobot lebih pada kata-kata kunci sentimen (misal: "sangat kecewa", "tidak suka"), alih-alih memproses seluruh sekuens secara merata.
4. **Menerapkan SMOTE atau data augmentation untuk kelas minoritas:** Ketidakseimbangan kelas (73% Positive vs 27% Negative) menyebabkan error rate lebih tinggi pada kelas Negative. Teknik oversampling SMOTE atau back-translation augmentation dapat menyeimbangkan distribusi tanpa mengorbankan data asli.
5. **Menambahkan modul interpretabilitas LIME/SHAP:** Saat ini model bersifat black-box. Mengintegrasikan LIME (Local Interpretable Model-agnostic Explanations) memungkinkan identifikasi kata-kata mana yang paling berkontribusi terhadap prediksi tiap kelas, membantu memvalidasi apakah model belajar dari fitur yang bermakna atau sekadar menghafal noise.

## DAFTAR PUSTAKA

- [1] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- [2] Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. arXiv preprint arXiv:1406.1078.
- [3] Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling. arXiv preprint arXiv:1412.3555.
- [4] Greff, K., Srivastava, R. K., Koutník, J., Steunebrink, B. R., & Schmidhuber, J. (2016). LSTM: A Search Space Odyssey. *IEEE Transactions on Neural Networks and Learning Systems*, 27(10), 2222–2232.
- [5] Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., and Purwarianti, A. (2020). IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding. arXiv preprint arXiv:2009.05387.

## LAMPIRAN A

### Berkas Metadata Proyek (JSON)

```
{
  "kode_kelompok": "Selasa-10",
  "topik_pilihan": 2,
  "nama_topik": "RNN / GRU / LSTM",
  "judul_proyek": "Analisis Sentimen Calon Presiden Indonesia 2024 Menggunakan Perbandingan Model RNN, LSTM, dan GRU",
  "abstrak_singkat": "Proyek ini bertujuan mengklasifikasikan sentimen publik terhadap 3 kandidat calon presiden 2024 berdasarkan data Twitter sebelum masa kampanye (Oktober 2022 - April 2023). Dataset publik dari Kaggle berjumlah 29.728 sampel digunakan untuk melatih tiga arsitektur Recurrent Neural Network: Simple RNN sebagai baseline, Bidirectional LSTM sebagai model utama, dan Bidirectional GRU sebagai pembanding. Data yang tidak seimbang antar kelas ditangani menggunakan class weight. Kinerja dievaluasi berdasarkan Accuracy, Precision, Recall, F1-Score, dan Confusion Matrix.",
  "metode_ai": [
    {
      "nama": "Long Short-Term Memory (LSTM)",
      "peran": "utama",
      "varian": "Bidirectional LSTM dengan Embedding Layer dan Dropout",
      "catatan": "Model utama menggunakan arsitektur Bidirectional untuk menangkap konteks dari kedua arah kalimat. Ditargetkan untuk mengatasi masalah vanishing gradient pada data teks sekuensial."
    },
    {
      "nama": "RNN",
      "peran": "baseline",
      "varian": "Vanilla Simple RNN dengan Embedding Layer",
      "catatan": "Digunakan sebagai baseline satu arah untuk membandingkan keunggulan arsitektur yang lebih kompleks."
    },
    {
      "nama": "Gated Recurrent Unit (GRU)",
      "peran": "pembanding",
      "varian": "Bidirectional GRU dengan Embedding Layer dan Dropout",
      "catatan": "Model pembanding menggunakan arsitektur Bidirectional, untuk melihat efisiensi waktu komputasi vs kinerja metrik dibanding LSTM."
    }
  ],
  "frameworks": [
    {
      "nama": "TensorFlow / Keras",
      "versi": "2.15",
      "kegunaan": "Pembuatan arsitektur dan proses training model (RNN, LSTM, GRU)"
    },
    {
      "nama": "Pandas",
      "versi": "Terbaru",
      "kegunaan": "Manipulasi dataframe, penggabungan data CSV, dan pembersihan teks (preprocessing)"
    },
    {
      "nama": "Scikit-learn",
      "versi": "Terbaru",
      "kegunaan": "Train-test split, label encoding, class weight, dan metrik evaluasi (Accuracy, F1-Score, Confusion Matrix)"
    }
  ]
}
```

```

        "nama": "Matplotlib & Seaborn",
        "versi": "Terbaru",
        "kegunaan": "Visualisasi grafik metrik evaluasi dan Confusion Matrix"
    }
],

"datasets": [
    {
        "nama": "Indonesia Presidential Candidate's Dataset, 2024",
        "tipe": "publik",
        "sumber": "Kaggle",
        "url_sumber_publik":
"https://www.kaggle.com/datasets/jocelyndumlao/indonesia-presidential-candidates-dat
aset-2024",
        "jumlah_sampel": 29728,
        "jumlah_kelas": 2,
        "proses_akuisisi_mandiri": "",
        "peran_di_proyek": "Dataset utama untuk proses training, validasi, dan
testing",
        "spek_rl": null
    }
],

"metrik_utama": [
    "Accuracy",
    "F1-Score (Macro/Weighted)",
    "Precision & Recall",
    "Confusion Matrix",
    "Waktu Pelatihan (Training Time)"
],

"klaim_bonus": ["B3"],

"anggota": [
    {
        "nama": "Reyhan Ahnaf Deannova",
        "npm": "2306267100",
        "peran_utama": "Data Engineer (Acquisition & Pipeline)",
        "focus_area": [
            "Pengunduhan dataset melalui Kaggle API",
            "Penggabungan dataset Ganjar, Prabowo, dan Anies menjadi satu dataframe
utama",
            "Penanganan missing values dan duplikasi data"
        ],
        "konsep_dikuasai_implementasi": [
            "Pandas DataFrame concatenation dan manipulasi index",
            "Pengelolaan API Kaggle di environment Google Colab"
        ],
        "konsep_dikuasai_teoris": [
            "Konsep integritas data saat penggabungan dari berbagai sumber",
            "Format data CSV dan struktur tabular"
        ],
        "bagian_laporan": [
            "Bab 1.3 (Ruang Lingkup & Batasan Sementara)",
            "Bab 3.2 (Bagian Dataset)"
        ],
        "bagian_kode": ["Bagian Data Acquisition & Merging"]
    },
    {
        "nama": "Muhammad Hilmi Al Muttaqi",
        "npm": "2306267082",
        "peran_utama": "Data Analyst (Preprocessing & EDA)",
        "focus_area": [
            "Pembersihan teks (menghapus URL, hashtag, angka, tanda baca)",
            "Tokenisasi dan padding sekuens teks",
            "Eksplorasi Data (EDA) distribusi sentimen antar kandidat"
        ],
        "konsep_dikuasai_implementasi": [
            "Penggunaan Regular Expression (Regex) untuk text cleaning",

```

```

        "Keras Tokenizer dan pad_sequences",
        "Pembuatan plot distribusi kelas (Class Balance)"
    ],
    "konsep_dikuasai_teor": [
        "Konsep representasi kata dalam bentuk numerik (Word Embedding)",
        "Pentingnya panjang sekuens yang seragam dalam batch training NLP"
    ],
    "bagian_laporan": [
        "Bab 1.1 (Topik yang Dipilih)",
        "Bab 1.2 (Rumusan Masalah)",
        "Bab 3.2 (Bagian Pra-pemrosesan)"
    ],
    "bagian_kode": ["Bagian Text Preprocessing & Tokenization"]
},
{
    "nama": "Bryan Herdianto",
    "npm": "2306210885",
    "peran_utama": "Model Engineer",
    "fokus_area": [
        "Pembuatan arsitektur model RNN, Bidirectional LSTM, dan Bidirectional GRU",
        "Hyperparameter tuning (batch size, learning rate, class weight)",
        "Penerapan Dropout dan EarlyStopping untuk menghindari overfitting"
    ],
    "konsep_dikuasai_implementasi": [
        "TensorFlow Keras Sequential API",
        "Penerapan Bidirectional wrapper pada LSTM dan GRU",
        "Class weight untuk mengatasi data imbalance",
        "EarlyStopping callback untuk menghentikan training saat val_loss tidak
membaik"
    ],
    "konsep_dikuasai_teor": [
        "Perbedaan mekanisme memori internal antara LSTM, GRU, dan RNN",
        "Keunggulan Bidirectional dalam menangkap konteks dua arah pada teks",
        "Masalah vanishing dan exploding gradient",
        "Fungsi aktivasi (Softmax/Sigmoid) pada layer klasifikasi akhir"
    ],
    "bagian_laporan": [
        "Bab 2.2 (Arsitektur Model yang Dipilih)",
        "Bab 2.3 (Justifikasi Awal Pemilihan Pendekatan)",
        "Bab 3.3 (Implementasi Model)"
    ],
    "bagian_kode": [
        "Bagian Pembangunan Model",
        "Bagian Training Loop",
        "Bagian Class Weight & EarlyStopping"
    ]
},
{
    "nama": "Adhikananda Wira Januar",
    "npm": "2306267113",
    "peran_utama": "Evaluator & Report Writer",
    "fokus_area": [
        "Evaluasi komparatif metrik ketiga model (Akurasi, F1, Waktu)",
        "Generasi dan interpretasi Confusion Matrix",
        "Analisis keterbatasan model dan bias data Twitter (Bonus B3)",
        "Penyusunan file metadata JSON dan integrasi laporan"
    ],
    "konsep_dikuasai_implementasi": [
        "Sklearn classification_report & confusion_matrix",
        "Plotting kurva validasi (Loss/Accuracy) dengan Matplotlib/Seaborn",
        "Format dan struktur standar JSON"
    ],
    "konsep_dikuasai_teor": [
        "Perbedaan metrik Accuracy vs F1-Score pada kasus klasifikasi teks",
        "Interpretasi False Positives dan False Negatives dari Confusion Matrix",
        "Pemahaman bias demografis pengguna Twitter di Indonesia"
    ],
    "bagian_laporan": [
        "Bab 2.1 (Studi Literatur)",

```

```

        "Bab 3.1 (Ringkasan Status per Tahap)",
        "Bab 3.4 (Hasil Eksperimen Sementara)",
        "Bab 4 (Pembagian Tugas & Deklarasi)"
    ],
    "bagian_kode": ["Bagian Evaluasi Metrik", "Bagian Visualisasi Hasil"]
}
],
"tautan": {
    "github": "https://github.com/bryanherdianto/tugas_akhir_ai",
    "colab":
"https://colab.research.google.com/drive/1V5x3ueBjGmk7cdL-1xVj5UD8VzfwVGPA?usp=shari
ng",
    "dataset_mandiri": null,
    "video_demo": "https://youtu.be/d7uHhrlRqZ8"
},
"ai_assistant_usage": {
    "digunakan": true,
    "tools": ["Gemini 3.1 Pro", "ChatGPT"],
    "bagian": [
        "Pembuatan awal struktur kode dan pipeline di file Proyek AI.ipynb",
        "Konsultasi pemilihan metrik evaluasi komparatif untuk model RNN/LSTM",
        "Review output notebook, identifikasi masalah underfitting dan class
imbalance",
        "Rekomendasi perbaikan: penambahan Bidirectional, class_weight, EarlyStopping,
dan peningkatan unit/epoch",
        "Restrukturisasi notebook: pemisahan cell dan penambahan markdown penjelasan",
        "Bantuan dalam menyusun dan menyesuaikan format file metadata.json"
    ],
    "estimasi_persentase": 35
}
}

```

## **LAMPIRAN B**

### **Tautan Repositori & Dataset**

**GitHub Repo:**

[https://github.com/bryanherdianto/tugas\\_akhir\\_ai](https://github.com/bryanherdianto/tugas_akhir_ai)

**Google Colab:**

<https://colab.research.google.com/drive/1V5x3ueBjGmk7cdL-1xVj5UD8VzfwVGPA?usp=sharing>

**Dataset mandiri: –**

**Video Demo:**

<https://youtu.be/d7uHhr1RqZ8>

**Status akses:** repositori publik / Colab dengan permission “anyone with the link can view”. Sudah diverifikasi terbuka pada 25 Mei 2025.

## LAMPIRAN C

### Research Participation Consent Form (*Informed Consent*)

**C.1 Brief Explanation.** *Research:* Development & validation of an *agentic AI* framework for supporting academic oral examinations. *Principal investigator:* [Name of course lecturer], Department of Computer Engineering, Universitas Indonesia. *Co-investigator:* a final-year undergraduate student supervised by the principal investigator. *Contact:* [principal investigator's email]. *Ethics review status:* **under review**. *Context:* data collection is conducted alongside the oral examination of the AI course's final assessment. The oral examination is held as part of the academic assessment regardless of the participant's research-participation choice.

**C.2 Data Collected.** Final report (PDF) and `metadata.json` file; audio and video recordings of the oral examination; automatic transcripts derived from those recordings; lecturer's *judgment* scores (*ground truth*) and AI system's *judgment* scores (test variable). **Not collected:** biometric data other than voice/face, or personal data beyond what is contained in the academic report.

**C.3 Data Management.** Participant names and student IDs (NPMs) will be stored anonymously — replaced with participant codes (P001, P002, ...) prior to analysis. The code-to-identity mapping table is stored separately, encrypted, and accessed only by the principal investigator. Publications (journal articles, conference papers, theses) will not contain individual identities. Data is stored with encryption on infrastructure managed by the research team; retention is 5 years after the research concludes, after which the data is permanently deleted. Access is limited to the principal and co-investigators; no third party may access without an amendment to this *consent*.

**C.4 Participant Rights.** (1) The right to decline participation without affecting the course grade. (2) The right to partial participation (e.g. report/metadata may be used, video recording may not). (3) The right to withdraw data at any time **until 30 June 2026** by emailing the principal investigator with the subject [Withdrawal] - [Name] - [NPM]; confirmation of deletion is provided within  $\leq 7$  working days. After 30 June 2026 the data will have entered the analysis phase and withdrawal becomes impractical. (4) The right to ask questions at any time to the principal investigator. (5) The right to receive a summary of the research findings once they are published (sent to the registered email).

**C.5 Individual Consent.** Each member completes their personal block on the following pages — one page per member. Tick **exactly one** of the three options (A / B / C), then sign with a wet signature or an *e-signature*.

## Individual Consent — Member 1

Full name : Bryan Herdianto  
Student ID (NPM) : 2306210885  
Group code : Selasa-10  
Email : bryan.herdianto@ui.ac.id

I have read Sections 1–4 and understood their contents. I voluntarily choose the following option:

**Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.

**Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)

**Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature

Witness / researcher's signature

  
( Bryan Herdianto )  
Date: 24/5/2026

( )  
Date:

## Individual Consent — Member 2

Full name : Reyhan Ahnaf Deannova  
Student ID (NPM) : 2306267100  
Email : reyhanahnafdeannova@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)

Participant's signature



(Reyhan Ahnaf Deannova )

Date: 25 May 2026

Witness / researcher's signature

( )

Date:

## Individual Consent — Member 3

Full name : Muhammad Hilmi Al Muttaqi  
Student ID (NPM) : 23062627082  
Email : muhammadhilmi.almuttaqib@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)

Participant's signature



Muhammad Hilmi Al Muttaqi

Date: 25 May 2026

Witness / researcher's signature

( )

Date:

## Individual Consent — Member 4

Full name : Adhikananda Wira Januar  
Student ID (NPM) : 2306267113  
Email : adhikaja@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)

Participant's signature



Adhikananda Wira Januar  
25 May 2026

Witness / researcher's signature

( )

Date: